

Universidad Nacional de San Agustín de Arequipa
Escuela Profesional de Ciencia de la Computación

Curso: Inteligencia Artificial



Réplica basada en la tesis de Ingeniería Mecatrónica

Algoritmos Genéticos para Determinar los Ángulos de Inclinación
Óptimos de Tubos al Vacío de Termas Solares en las
Principales Ciudades del Perú

Presentado por:

Mamani Yucra Edilson Bonet

Docente:

Rolando Cardenas Talavera

Arequipa, 21 de julio de 2026

1. Introducción

El Perú es uno de los países con mayor potencial de radiación solar del planeta, alcanzando niveles de insolación extremadamente altos en gran parte de su territorio. Este recurso es aprovechado ampliamente por las termas solares de tubos al vacío, sistemas de bajo costo utilizados para el calentamiento doméstico de agua. Sin embargo, la eficiencia de estos sistemas depende críticamente del ángulo de inclinación con el que se instalan los colectores, un parámetro que suele fijarse de manera empírica o siguiendo recomendaciones genéricas del fabricante, sin considerar las particularidades geográficas de cada ciudad (latitud, altitud y perfil de radiación anual).

La tesis de referencia, desarrollada en el área de Ingeniería Mecatrónica, aborda este problema aplicando **Algoritmos Genéticos (AG)** —una técnica de Inteligencia Artificial bio-inspirada en la selección natural— para determinar de forma automática el ángulo de inclinación que maximiza la energía solar anual recolectada por un tubo al vacío, en seis de las principales ciudades del Perú: Trujillo, Piura, Iquitos, Tacna, Arequipa y Puno.

El presente trabajo tiene como objetivo replicar íntegramente esta metodología **desde cero**, sin el uso de ninguna librería de Inteligencia Artificial u optimización (ni DEAP, ni `scipy`, ni similares), implementando manualmente tanto el modelo matemático de geometría solar que define la función objetivo, como el propio Algoritmo Genético con sus operadores de selección, cruzamiento y mutación. Adicionalmente, se propone e implementa una **mejora** justificada al algoritmo original, convirtiéndolo en un algoritmo memético, y se comparan los resultados obtenidos contra los reportados por el autor de la tesis.

2. Descripción del problema real resuelto

El problema real consiste en **maximizar la energía solar anual recolectable por unidad de longitud de un tubo al vacío**, variando su único parámetro de diseño libre: el ángulo de inclinación β (en grados).

Un tubo al vacío recibe radiación solar directa y difusa a lo largo del año. La cantidad de energía captada depende de una geometría solar compleja que involucra:

- La posición del sol en cada instante del día y del año (declinación, ángulo horario, ángulo cenital).
- La atenuación atmosférica de la radiación (modelo de cielo despejado de Hottel).
- El sombreado mutuo entre tubos adyacentes, que depende del ángulo de inclinación β , el diámetro de los tubos ($D_1 = 47\text{mm}$ interior, $D_2 = 58\text{mm}$ cobertor) y la distancia de separación entre sus centros (B).

Existe una relación no lineal y no monótona entre β y la energía anual recolectada: ángulos muy bajos maximizan la captación al mediodía pero desaprovechan la radiación de mañana/tarde; ángulos muy altos reducen el área efectiva de captación y aumentan el autosombreado. Esto genera una función objetivo **unimodal** (un único máximo) en el rango de interés, razón por la cual el problema es un candidato natural —y a la vez relativamente sencillo, al tratarse de una sola variable de decisión continua— para ser resuelto mediante optimización evolutiva.

La función objetivo replicada corresponde a la ecuación (34) de la tesis: la **energía anual acumulada** H_{anual} , obtenida sumando, para los 365 días del año, la integral diaria de la potencia total (directa + difusa) incidente sobre el tubo, entre la hora del amanecer y la del atardecer.

Se replicaron los datos geográficos exactos (latitud, longitud y altitud, tomados en la plaza de armas) de las seis ciudades analizadas en la tesis, así como la geometría de los tubos ($D_1 = 47\text{mm}$, $D_2 = 58\text{mm}$, $B = 80\text{mm}$, valor típico usado por la tesis).

Cuadro 1: Dataset de coordenadas geográficas y parámetros de los tubos al vacío.

Ciudad	Latitud (°)	Longitud (°)	Altitud (km)
Trujillo	-8.1117	-79.0286	0.034
Tacna	-18.0137	-70.2510	0.552
Arequipa	-16.4154	-71.5218	2.335
Piura	-5.1971	-80.6266	0.055
Puno	-15.8405	-70.0279	3.827
Iquitos	-3.7493	-73.2444	0.106
Parámetros fijos del tubo al vacío:			
Diámetro interno (D_1) = 47 mm, Diámetro externo (D_2) = 58 mm			
Longitud (L_{tubo}) = 1.80 m, Separación entre centros (B) = 80 mm			

3. Explicación del algoritmo original (de la tesis)

3.1. Función objetivo y modelo matemático

El modelo matemático de geometría solar se implementó desde cero (usando únicamente el módulo estándar `math` de Python), reproduciendo con fidelidad las ecuaciones descritas en la tesis, basadas en Duffie, Beckman & Blair (2020) y en Tang, Gao & Yu (2009):

$$\delta = \text{declinación solar (polinomio de Spencer, 1971)} \quad (1)$$

$$\omega_{ss} = \min\left(\omega_s, \cos^{-1}(-\tan \delta \tan(\phi + \beta))\right) \quad (\text{atardecer, plano inclinado, hemisferio sur}) \quad (2)$$

$$\tau_b = r_0 a_0 + r_1 a_1 \exp\left(\frac{-r_k k}{\cos \theta_Z}\right) \quad (\text{transmitancia directa, modelo de Hottel}) \quad (3)$$

$$G_{bn} = G_{on} \cos \theta_Z \tau_b, \quad \tau_d = 0,271 - 0,294 \tau_b, \quad G_d = G_{on} \cos \theta_Z \tau_d \quad (4)$$

$$P_{total} = D_1 L_{tubo} \left(G_{bn} \cos \theta_t f(\Omega) + \pi G_{d\beta} F \right) \quad (\text{ecuación 32 de la tesis}) \quad (5)$$

$$H_{anual} = \sum_{n=1}^{365} \int_{-\omega_{ss}}^{\omega_{ss}} P_{total}(t) dt \quad (\text{ecuación 34 de la tesis, función objetivo}) \quad (6)$$

donde $f(\Omega)$ es la función de aceptación angular y F el factor de forma difuso, ambos dependientes de los ángulos críticos Ω_0, Ω_1 determinados por la geometría de los tubos (ecuaciones 25-31 de la tesis). La integral diaria se evaluó numéricamente mediante la **regla de Simpson compuesta**, implementada también desde cero. A continuación se muestra la función principal en Python que calcula la energía anual iterando sobre los 365 días del año:

```
def energia_anual_MJ(phi_deg, altitud_km, beta_deg, B_mm, paso_dias=1, n_pasos=241):
    :
    total = 0.0
    dias = range(1, 366, paso_dias)
    for n in dias:
        total += energia_diaria_MJ(n, phi_deg, altitud_km, beta_deg, B_mm, n_pasos=
            n_pasos)
    if paso_dias > 1:
        total *= 365.0 / len(dias)
    return total
```

3.2. Representación y operadores del Algoritmo Genético

Siguiendo la sección 3.4.2 de la tesis (que reporta el uso de la librería DEAP), se implementó un AG con las siguientes características, replicadas manualmente en Python puro (módulo `random`

únicamente):

Cuadro 2: Parámetros configurados para el Algoritmo Genético original.

Parámetro	Valor / Método
Representación	Valor real (ángulo β en grados)
Función de aptitud	Energía anual $H_{anual}(\beta)$ (a maximizar)
Tamaño de población	50 individuos
Número de generaciones	15
Método de selección	Torneo (tamaño $k = 3$)
Método de cruzamiento	Blend Crossover ($\alpha = 0,5$), probabilidad $p_c = 0,7$
Método de mutación	Gaussiana ($\sigma = 10\%$), probabilidad $p_m = 0,1$
Reemplazo	Generacional puro (sin elitismo)

El rango de búsqueda de β se acotó, para cada ciudad, según la región donde la propia tesis (Tablas 5 y 6) reportó la mayor energía anual mediante el barrido inicial de ángulos (0° - 35°). El siguiente código muestra cómo se implementó la selección por torneo y la mutación en el algoritmo puro:

```
def seleccion_torneo(poblacion, k=3):
    seleccionados = []
    for _ in range(len(poblacion)):
        torneo = random.sample(poblacion, k)
        ganador = max(torneo, key=lambda ind: ind["fitness"])
        seleccionados.append(ganador.copy())
    return seleccionados

def mutacion_gaussiana(ind, lo, hi, sigma, prob_mut=0.1):
    if random.random() < prob_mut:
        ind["beta"] += random.gauss(0, sigma)
        # Asegurar que no exceda los limites
        ind["beta"] = max(lo, min(hi, ind["beta"]))
```

4. Explicación de la mejora implementada

4.1. Motivación

El propio autor de la tesis, en la sección 3.4.4 (“Evaluación de Resultados”), valida sus resultados del AG comparándolos contra un método numérico clásico: la **Búsqueda de la Sección Áurea** (*Golden Section Search*), un método de optimización unidimensional que converge de forma muy precisa cuando la función es unimodal en el intervalo de búsqueda —exactamente el caso de este problema—. Esto sugiere una mejora natural: en lugar de usar la búsqueda áurea solo como verificación externa posterior, **integrarla dentro del propio ciclo evolutivo**, dando lugar a un **Algoritmo Memético** (Moscato, 1989): la combinación de un algoritmo evolutivo (exploración global) con una búsqueda local exacta (explotación fina).

Adicionalmente, se identificó una debilidad metodológica en el AG original: al usar reemplazo generacional puro (sin elitismo), el mejor individuo encontrado en una generación **puede perderse** si no sobrevive la selección, el cruce o la mutación de la siguiente generación —un problema conocido de los AG generacionales simples.

4.2. Componentes de la mejora propuesta

1. **Elitismo**: se conservan siempre los 2 mejores individuos de cada generación, reinsertándolos en el lugar de los 2 peores individuos de la descendencia. Esto garantiza una convergencia **monótona no decreciente** del mejor fitness.

2. **Mutación gaussiana adaptativa:** la desviación estándar σ de la mutación decrece linealmente a lo largo de las generaciones (de $\sigma_{inicial} = 10\%$ del rango a $\sigma_{final} = 1,5\%$), pasando de una fase de exploración amplia a una fase de explotación fina, en lugar de mantener una σ fija durante las 15 generaciones.
3. **Refinamiento memético (Lamarckiano):** cada 5 generaciones, se aplica la Búsqueda de la Sección Áurea en un entorno pequeño ($\pm 8\%$ del rango total) alrededor del mejor individuo de la población, y si el resultado refinado mejora el fitness, reemplaza directamente al individuo en la población (aprendizaje Lamarckiano).

Esta combinación es un enfoque estándar y ampliamente documentado en la literatura de optimización evolutiva para problemas continuos de baja dimensionalidad, y tiene la ventaja adicional de ser *coherente* con la propia validación metodológica que el autor de la tesis ya realizó.

5. Resultados obtenidos

Ambos algoritmos (original y mejorado) fueron ejecutados con los mismos parámetros (población=50, generaciones=15, $p_c = 0,7$, $p_m = 0,1$) y la misma semilla aleatoria, para las 6 ciudades de la tesis. El detalle generación por generación de cada ejecución (fitness del mejor, promedio y peor individuo por generación) se documenta en el archivo de salida `resultados_algoritmo_genetico.txt` adjunto al presente informe.

5.1. Tabla comparativa de ángulos óptimos

Cuadro 3: Ángulo óptimo β^* (grados) y energía anual (MJ/m) para $B = 80\text{mm}$, comparado contra la tesis original.

Ciudad	β^* Tesis (°)	β^* AG Original (°)	β^* AG Mejorado (°)	Energía Tesis (MJ/m)	Energía (este trabajo) (MJ/m)
Trujillo	5.62	4.95	4.97	718.82	689.72
Piura	3.99	3.25	3.25	725.11	695.77
Iquitos	2.87	2.47	2.48	730.23	700.33
Tacna	13.64	11.75	11.77	719.45	685.19
Arequipa	12.66	11.30	11.36	793.56	746.82
Puno	12.22	11.05	10.98	804.70	755.28

Concordancia de ángulos: la diferencia absoluta promedio entre el ángulo óptimo hallado por el AG (ambas versiones) y el reportado por la tesis es de aproximadamente 1,1, con la ciudad de Iquitos mostrando la mayor cercanía ($-0,40$) y Tacna la mayor discrepancia ($-1,89$). En las 6 ciudades se conserva el mismo orden relativo de los ángulos óptimos (Iquitos < Piura < Trujillo < Puno $\approx$ Arequipa < Tacna), lo cual confirma que el modelo matemático reimplementado captura correctamente la tendencia física esperada: ciudades de mayor latitud requieren mayor inclinación.

Concordancia de energía: la energía anual obtenida en este trabajo es sistemáticamente entre un 94 % y un 96 % de la reportada en la tesis (razón promedio $\approx 0,95$) para las 6 ciudades. Esta diferencia proporcional y consistente es esperable, dado que el modelo se reimplementó desde cero a partir de las ecuaciones del documento, sin acceso al código fuente original ni a los supuestos de calibración numérica no explicitados por el autor (p.ej. resolución exacta de la integración numérica, manejo de casos límite del sombreado). El hecho de que la razón sea consistente entre las 6 ciudades (no aleatoria) sugiere una diferencia sistemática de calibración más que un error conceptual del modelo.

5.2. Comparación de convergencia: AG Original vs. AG Mejorado

La Figura 1 muestra la evolución del mejor y el peor individuo de la población, generación a generación, para la ciudad de Trujillo (resultado representativo de las 6 ciudades).




Figura 1: Convergencia del AG Original vs. AG Mejorado (Trujillo). El AG Mejorado mantiene una población mucho más homogénea (peor individuo mucho más cercano al mejor) gracias al elitismo y la mutación adaptativa.

Ambos algoritmos alcanzan prácticamente el mismo valor de fitness máximo (la diferencia entre el mejor individuo de ambos en la generación 15 es menor a 0,001 %), lo cual es esperable dado que el problema es unidimensional y unimodal —relativamente sencillo para cualquier AG bien configurado—. La diferencia relevante aparece en la **robustez de la convergencia de toda la población**: en el AG Original, el peor individuo de la generación 15 todavía se encuentra a 3,82 MJ/m del mejor (fitness peor = 687,10 vs. mejor = 690,92), evidenciando que, sin elitismo, una fracción de la población puede seguir siendo subóptima incluso al final de la ejecución. En el AG Mejorado, esa misma brecha se reduce a apenas 0,02 MJ/m (peor= 690,90 vs. mejor= 690,92), es decir, una reducción de más del **99 %** en la dispersión final de la población. Este comportamiento se repitió de forma consistente en las 6 ciudades evaluadas.

5.3. Verificación cruzada

Como verificación adicional (análoga a la que realiza la propia tesis en su sección 3.4.4), se ejecutó un **barrido exhaustivo** (fuerza bruta, paso de 0,05) sobre el mismo modelo matemático implementado. En las 6 ciudades, el óptimo hallado por barrido coincidió con el hallado por ambas versiones del AG con una diferencia menor a 0,05 (el propio paso de discretización del barrido), confirmando que ambos algoritmos genéticos convergieron correctamente al máximo global de la función objetivo implementada.

6. Conclusiones

1. Se logró implementar desde cero, sin ninguna librería de Inteligencia Artificial ni de optimización, tanto el modelo matemático de geometría solar (ecuaciones 1-34 de la tesis) como un Algoritmo Genético que replica fielmente la metodología descrita en la sección 3.4.2 (población=50, generaciones=15, cruzamiento=0.7, mutación=0.1).

2. El ángulo óptimo de inclinación hallado para las 6 ciudades concuerda de forma cercana con el reportado en la tesis (diferencia promedio $\approx 1,1$), y conserva exactamente el mismo orden relativo entre ciudades, validando que el problema de optimización (una función unimodal de la energía anual en función de β) fue replicado correctamente en su estructura esencial.
3. La energía anual absoluta calculada difiere de la reportada por el autor en un factor sistemático de aproximadamente 0.95, atribuible a diferencias de calibración numérica no explicitadas en el documento original (y no a un error conceptual, dado que la razón es consistente entre ciudades).
4. La mejora propuesta —un **algoritmo memético** que combina elitismo, mutación gaussiana adaptativa y refinamiento local con Búsqueda de la Sección Áurea— no modificó significativamente el valor final del óptimo (por tratarse de un problema unidimensional relativamente sencillo), pero sí mejoró sustancialmente la **robustez de la convergencia**, reduciendo en más del 99 % la dispersión de fitness entre el mejor y el peor individuo de la población final.
5. Esta mejora es especialmente relevante y generalizable a problemas de mayor dimensionalidad (por ejemplo, si se optimizara simultáneamente el ángulo β y la distancia entre tubos B), donde el elitismo y el refinamiento local memético previenen la pérdida de buenas soluciones y aceleran la convergencia sin aumentar el número de generaciones.
6. El trabajo demuestra la viabilidad de aplicar Algoritmos Genéticos, implementados completamente desde cero, a un problema real de ingeniería mecatrónica/energías renovables, reforzando el carácter interdisciplinario de la Inteligencia Artificial como herramienta de optimización en dominios de ingeniería física.

7. Referencias bibliográficas

- Autor de la tesis (2025). *Algoritmos genéticos para determinar los ángulos de inclinación óptimos de tubos al vacío de termas solares en las principales ciudades del Perú*. Tesis de Ingeniería Mecatrónica.
- Beckman, W.A., Duffie, J.A., & Blair, N. (2020). *Solar Engineering of Thermal Processes, Photovoltaics and Wind* (5ta ed.). Wiley.
- Tang, R., Gao, W., & Yu, Y. (2009). Optimal tilt-angles of all-glass evacuated tube solar collectors. *Energy*, 34, 1387-1395.
- Hottel, H.C. (1976). A simple model for estimating the transmittance of direct solar radiation through clear atmospheres. *Solar Energy*, 18(2), 129-134.
- Liu, B.Y.H., & Jordan, R.C. (1960). The interrelationship and characteristic distribution of direct, diffuse and total solar radiation. *Solar Energy*, 4(3), 1-19.
- Spencer, J.W. (1971). Fourier series representation of the position of the sun. *Search*, 2(5), 172.
- Moscato, P. (1989). *On Evolution, Search, Optimization, Genetic Algorithms and Martial Arts: Towards Memetic Algorithms*. Caltech Concurrent Computation Program, Report 826.
- Fortin, F.A., De Rainville, F.M., Gardner, M.A., Parizeau, M., & Gagné, C. (2012). DEAP: Evolutionary algorithms made easy. *Journal of Machine Learning Research*, 13(1), 2171-2175.